

LANE *SHIFT*

变道之间：强化学习驾驶对决

在动态车流中，学习安全与效率的取舍。
从环境设计、策略训练，到可复现评估与交互展示。

同一起点 两种驾驶



左侧由玩家操作，右侧由 PPO 决策。
初始车流相同，之后独立响应动作。
胜负先看安全，再看达标和得分。

55 s

连续高压
短演示路线

5 Hz

决策频率
双方相同

PPO

正式对手
本地固定权重

把驾驶写成学习任务

状态输入 → 策略网络 → 高层驾驶动作

OBSERVATION

30 维状态

本车 6 维。
三车道各 8 维前后车信息。
距离、速度与侧向运动。

结构化数值输入 · 不读取截图

POLICY

两层 MLP

策略分支输出动作概率。
价值分支估计长期回报。
各分支隐藏层 128 → 128。

训练使用价值估计 · 比赛执行策略

ACTION

5 种动作

左换道 · 保持 · 右换道
加速 · 减速
每秒做 5 次决策。

底层物理仿真 15 HZ

依据：rl_course/driving_env.py: LaneObservation; 已部署 PPO 权重中的 policy_kwargs

从交互反馈中更新策略

- 01 观察车流，按当前策略选择动作。
- 02 仿真执行，获得新状态和奖励。
- 03 收集一批经历，估计动作的长期优势。
- 04 PPO 限制过大的更新，再继续交互。

训练时更新参数；比赛时只加载权重做推理。

依据：rl_course/train_v3.py；Stable-Baselines3 PPO 文档（参考链接见讲稿）



奖励定义驾驶偏好

正式高手与效率候选使用不同奖励设置；游戏计分规则保持一致。

正式高手 / V3.1

先学会安全通行

奖励前进、有效超车与完赛。
惩罚危险跟车、冒险换道和反复变道。

- 每米 +0.025；每次超车 +0.4
- 事故惩罚项合计 -30

依据：rl_course/driving_env.py: _reward; driving_env_v3.py; train_challenge_models.py: TrainingRoad

效率候选 / ITERATION 4

再提高通行效率

提高前进和超车的正反馈。
同时加重事故惩罚，观察真实取舍。

- 未碰撞且在道路上：额外每米 +0.035、超车 +0.2
- 事故惩罚项提高至 -60


06 / 开发评估曲线

训练更久未必更好

上：平均行驶里程

下：累计危险时间

蓝线：正式部署检查点



起点已继承 PPO，不是从零训练。

每点为同一组 24 局，回合均为 45 秒。

开发曲线与后面的独立测试分开解读。

50.18 万	17.5 万	17 次
本次安全微调 501,760 步	正式部署点 另有上游训练	归档开发评估 未平滑、单训练种子

效率提升伴随安全代价

策略	达标率 · 横轴 0-100%	达标率	碰撞局数
正式 PPO		72.3%	0 / 300
PPO 候选		78.3%	8 / 300
DQN 候选		56.7%	65 / 300
A2C 候选		79.0%	5 / 300
规则驾驶		63.3%	0 / 300

正式 PPO 比规则驾驶高 9.0 个百分点。
A2C 达标更多，但新增碰撞，未通过升级门槛。

依据：iteration_4/report.json：models*.summary；每策略 n=300；达标=安全完赛且满足里程

正式对手

PPO

高压关待改进

强化学习驾驶对决

构建可学习的任务

结构化车流、状态动作设计、奖励与交互展示形成完整流程。

按评估结果选择对手

PPO 用于正式对决；候选实验展示通行效率与碰撞的取舍。

明确目前的边界

高压关仍待改善；尚无足够证据支持“超过人类”。