

LANE *SHIFT*

变道之间：强化学习驾驶对决

在动态车流中，学习安全与效率的取舍。
从环境设计、策略训练，到可复现评估与交互展示。

01 / 交互展示

同一起点 两种驾驶



左侧由玩家操作，右侧由 PPO 决策。
初始车流相同，之后独立响应动作。
胜负先看安全，再看达标和得分。

55 s

连续高压
短演示路线

5 Hz

决策频率
双方相同

PPO

正式对手
本地固定权重

把驾驶写成学习任务

状态输入 → 策略网络 → 高层驾驶动作

OBSERVATION

30 维状态

本车 6 维。
三车道各 8 维前后车信息。
距离、速度与侧向运动。

结构化数值输入 · 不读取截图

POLICY

两层 MLP

策略分支输出动作概率。
价值分支估计长期回报。
各分支隐藏层 128 → 128。

训练使用价值估计 · 比赛执行策略

ACTION

5 种动作

左换道 · 保持 · 右换道
加速 · 减速
每秒做 5 次决策。

底层物理仿真 15 HZ

依据：rl_course/driving_env.py: LaneObservation; 已部署 PPO 权重中的 policy_kwargs

从交互反馈中更新策略

- 01 观察车流，按当前策略选择动作。
- 02 仿真执行，获得新状态和奖励。
- 03 收集一批经历，估计动作的长期优势。
- 04 PPO 限制过大的更新，再继续交互。

训练时更新参数；比赛时只加载权重做推理。

依据：rl_course/train_v3.py；Stable-Baselines3 PPO 文档（参考链接见讲稿）



奖励定义驾驶偏好

微调前后使用不同训练奖励；游戏计分规则保持一致。

先学会安全通行

奖励前进、有效超车与完赛。
惩罚危险跟车、冒险换道和反复变道。

- 每米 +0.025；每次超车 +0.4
- 事故惩罚项合计 -30

兼顾效率与跟车安全


增加前进与安全达标的奖励。
危险跟车额外 -0.25 / 步。

- 未碰撞且在道路上：额外每米 +0.015；安全达标 +6
- 事故惩罚项提高至 -60

06 / 上游开发记录

训练更久 未必更好

上：平均行驶里程
下：累计危险时间
蓝线：当时部署检查点



起点已继承 PPO，不是从零训练。
每点为同一组 24 局，回合均为 45 秒。
开发曲线与后面的独立测试分开解读。

50.18 万	17.5 万	17 次
本次安全微调 501,760 步	当时部署点 另有上游训练	归档开发评估 未平滑、单训练种子

10 / PPO 微调验收

本轮微调： 在新道路上验收

继承效率微调权重 · 危险跟车惩罚 · 参考策略约束

微调前 PPO

同一组 300 局新道路

73.7% 2/300

安全达标率 碰撞局数

平均得分 1548 分

高压关达标率： 35% → 37%（各 100 局）。
未过全部门槛，保留原 PPO。

微调后 PPO

同一组 300 局新道路

74.0% 4/300

安全达标率 碰撞局数

平均得分 1547 分

依据： iteration_6/report.json、 selection.json、 test_previous.json、 test_candidate.json； 每模型 300 局

正式对手 PPO 训练与验证

强化学习驾驶对决

构建可学习的任务

结构化车流、状态动作设计、奖励与交互展示形成完整流程。

按评估结果选择对手

PPO 用于正式对决；候选实验展示通行效率与碰撞的取舍。

明确目前的边界

仍有道路未达标；尚无足够证据支持“超过人类”。