

LANE *SHIFT*

变道之间：强化学习驾驶对决

在动态车流中，学习安全与效率的取舍。

从环境设计、策略训练，到可复现评估与交互展示。

01 / 交互展示

同一起点 两种驾驶



左侧由玩家操作，右侧由 PPO 决策。
初始车流相同，之后独立响应动作。
胜负先看安全，再看达标和得分。

55 s

连续高压
短演示路线

5 Hz

决策频率
双方相同

PPO

正式对手
本地固定权重

挑战来自车流关系

持续生成交通编队，让选择车道与时机成为整段行程的问题。

CONVOY

慢车编队

前方慢车阻挡通行。
判断何时离开当前车道。

35 秒 · 790 米

WEAVE

交织车流

邻道后车快速接近。
同时观察前方与后方。

45 秒 · 900 米

PRESSURE

连续高压

多车道受阻并持续补车。
在安全窗口中争取效率。

55 秒 · 1270 米

依据：rl_course/driving_env_v3.py：交通编队、持续补车；challenge_rules.py：关卡目标

把驾驶写成学习任务

状态输入 → 策略网络 → 高层驾驶动作

OBSERVATION

30 维状态

本车 6 维。
三车道各 8 维前后车信息。
距离、速度与侧向运动。

结构化数值输入 · 不读取截图

POLICY

两层 MLP

策略分支输出动作概率。
价值分支估计长期回报。
各分支隐藏层 128 → 128。

训练使用价值估计 · 比赛执行策略

ACTION

5 种动作

左换道 · 保持 · 右换道
加速 · 减速
每秒做 5 次决策。

底层物理仿真 15 HZ

依据：rl_course/driving_env.py: LaneObservation; 已部署 PPO 权重中的 policy_kwargs

04 / 强化学习闭环

从交互反馈中更新策略

- 01 观察车流，按当前策略选择动作。
- 02 仿真执行，获得新状态和奖励。
- 03 收集一批经历，估计动作的长期优势。
- 04 PPO 限制过大的更新，再继续交互。

训练时更新参数；比赛时只加载权重做推理。

依据：rl_course/train_v3.py；Stable-Baselines3 PPO 文档（参考链接见讲稿）



奖励定义驾驶偏好

微调前后使用不同训练奖励；游戏计分规则保持一致。

先学会安全通行

奖励前进、有效超车与完赛。
惩罚危险跟车、冒险换道和反复变道。

- 每米 +0.025；每次超车 +0.4
- 事故惩罚项合计 -30

兼顾效率与跟车安全

增加前进与安全达标的奖励。
危险跟车额外 -0.25 / 步。

- 未碰撞且在道路上：额外每米 +0.015；安全达标 +6
- 事故惩罚项提高至 -60

依据：driving_env.py；driving_env_v3.py；train_refinement.py：RefinementRoad；train_safety_refinement.py：训练奖励与参考策略 KL 损失


06 / 上游开发记录

训练更久 未必更好

上：平均行驶里程

下：累计危险时间

蓝线：当时部署检查点



起点已继承 PPO，不是从零训练。

每点为同一组 24 局，回合均为 45 秒。

开发曲线与后面的独立测试分开解读。

50.18 万	17.5 万	17 次
本次安全微调 501,760 步	当时部署点 另有上游训练	归档开发评估 未平滑、单训练种子

上一轮：三种算法各回答什么

该轮五次运行新增 700,816 步交互，保留各自初始化来源。

PPO / 已有策略微调

稳定更新策略

从正式高手出发。
检验新奖励能否改善效率。

该轮 200,704 步

DQN / 从零后续训

学习动作价值

经验回放与目标网络。
提供另一类学习方法作对照。

125,008 + 200,000 步

A2C / 两种初始化

比较策略更新

从零训练；另试 PPO 权重初始化。
后续均使用 A2C 更新。

125,056 + 50,048 步

依据：iteration_4/*/progress.json；train_challenge_models.py；SB3 PPO / DQN / A2C 文档；历史实验，与本轮使用不同测试道路。

先冻结，再看独立结果



三关 × 100 个未见种子 = 每策略 300 局。
同一组初始道路，同时比较碰撞、达标率与得分。

依据：iteration_6/selection.json； release_refinement.py

09 / 独立测试结果

上一轮：效率提升伴随安全代价

策略	达标率 · 横轴 0-100%	达标率	碰撞局数
原 PPO		72.3%	0 / 300
PPO 候选		78.3%	8 / 300
DQN 候选		56.7%	65 / 300
A2C 候选		79.0%	5 / 300
规则驾驶		63.3%	0 / 300

原 PPO 比规则驾驶高 9.0 个百分点。
A2C 达标更多，但新增碰撞，未通过升级门槛。

依据：iteration_4/report.json：models*.summary；每策略 n=300；达标=安全完赛且满足里程；历史实验，与本轮使用不同测试道路。

本轮微调： 在新道路上验收

继承效率微调权重 · 危险跟车惩罚 · 参考策略约束

微调前 PPO

同一组 300 局新道路

73.7% 2/300

安全达标率 碰撞局数

平均得分 1548 分

高压关达标率： 35% → 37%（各 100 局）。
未过全部门槛，保留原 PPO。

微调后 PPO

同一组 300 局新道路

74.0% 4/300

安全达标率 碰撞局数

平均得分 1547 分

依据： iteration_6/report.json、 selection.json、 test_previous.json、 test_candidate.json； 每模型 300 局

正式对手

PPO

训练与验证

强化学习驾驶对决

构建可学习的任务

结构化车流、状态动作设计、奖励与交互展示形成完整流程。

按评估结果选择对手

PPO 用于正式对决；候选实验展示通行效率与碰撞的取舍。

明确目前的边界

仍有道路未达标；尚无足够证据支持“超过人类”。

正式 PPO 配置

01

网络

30 维输入
128 → 128 隐藏层
5 维动作概率
独立价值分支

02

采样

4 个向量环境
每环境 512 步
共 2048 条交互
每批 256 条

03

更新

学习率 $3e-4$
折扣率 0.99
GAE 0.95
每轮 8 epoch

04

约束与探索

PPO 裁剪 0.2
熵系数 0.008
仅训练时更新
推理确定性选动作

依据：v3_expert-b4f0d5f66de4.zip：PPO.load 后读取属性；train_v3.py

常见问题

AI 会现场学习吗？

不会。训练已完成，现场加载固定模型做推理。

三个算法一起开车？

不会。比赛只有正式 PPO；其他模型用于离线对照。

为什么不选 A2C？

达标率提高，但碰撞增加，没有通过预设升级门槛。

零碰撞等于安全？

只代表这 300 局的观测结果，不保证其他道路零风险。

已经超过人类吗？

尚未建立系统人类基准，现场一局不能证明。

项目贡献在哪里？

环境、奖励、训练评估与交互整合；算法采用 SB3 实现。